

Inferencia causal

Diseño e implementación de experimentos en ciencias sociales

Departamento de Economía (UdelaR)

Tema 1. Inferencia causal

- ▶ El modelo de causalidad Neyman–Rubin
- ▶ Experimentos aleatorizados y validez
- ▶ Asignación aleatoria simple
- ▶ Estimandos (ATE, ITT, CACE, SATE, PATE, ATT, CATE, mediación)

Lecturas

- ▶ Gerber, Alan S., and Donald P. Green. 2012. *Field Experiments: Design, Analysis, and Interpretation*. New York: W.W. Norton. (FEDAI). capítulos 1-2.
- ▶ Imbens, G. W., & Rubin, D. B. (2015). Causal inference in statistics, social, and biomedical sciences. Cambridge University Press. (CISSBS), capítulos 1-2.
- ▶ 10 Types of Treatment Effect You Should Know About
- ▶ Aronow, P. M. and Samii, C. (2016). “Does regression produce representative estimates of causal effects?” *American Journal of Political Science*, 60(1):250–267
- ▶ Barabas, J. and Jerit, J. (2010). “Are survey experiments externally valid?” *American Political Science Review*, 104(2):226–242

Causalidad

Qué es la causalidad

“[...] something that makes a difference, and the difference it makes must be a difference from what would have happened without it.”¹

¹Lewis, David. Causation. *The journal of philosophy* (1973): 556-567

Qué es la causalidad

- ▶ “ X causó Y ” (Y está presente e Y no habría estado presente si X no hubiera estado presente).

Qué es la causalidad

- ▶ “ X causó Y ” (Y está presente e Y no habría estado presente si X no hubiera estado presente).
- ▶ El “efecto” de X sobre Y es la diferencia entre el valor que Y habría tomado dado un valor de X y el valor que Y habría tomado dado otro valor de X .

Qué es la causalidad

- ▶ “ X causó Y ” (Y está presente e Y no habría estado presente si X no hubiera estado presente).
- ▶ El “efecto” de X sobre Y es la diferencia entre el valor que Y habría tomado dado un valor de X y el valor que Y habría tomado dado otro valor de X .
- ▶ La diferencia de resultados surge de considerar un *contrafactual*.

Efecto causal (Imbens y Rubin)

El efecto de una intervención/programa/política en un indicador de interés (Y) es la **diferencia entre dos resultados potenciales** de un individuo/grupo (con/sin “tratamiento”), pero no depende de cuál de dichos resultados es observado.

Resultados potenciales

- ▶ $Y_i(1)$ resultado de la unidad i que se observaría si recibiera un tratamiento ($T_i = 1$).
- ▶ $Y_i(0)$ el resultado que se observaría en la unidad i si no recibiera el tratamiento ($T_i = 0$).

Efecto causal (Imbens y Rubin)

$$\tau_i = Y_i(1) - Y_i(0)$$

- ▶ τ_i es efecto causal del tratamiento para la unidad i

Resultados potenciales

Unidad	$Y(0)$	$Y(1)$	$Y(1) - Y(0)$
1	3	4	1
2	5	6	1
3	4	3	-1
4	6	5	-1
6	7	7	0
Media	5	5	0

- ▶ Tenemos el efecto del tratamiento para cada individuo.
- ▶ Obsérvese la heterogeneidad en los efectos del tratamiento a nivel individual.
- ▶ Pero sólo tenemos como máximo un resultado potencial para cada individuo, lo que significa que no conocemos estos efectos del tratamiento.

Características de esta definición de efecto causal

1. Es necesario definir la condición de control para definir un efecto causal.
 - ▶ Digamos que $T = 1$ significa presupuesto participativo. ¿Es $T = 0$ la ausencia del PP? ¿Es $T = 0$ una reunión comunitaria sobre un tema diferente? ¿Es $T = 0$ un folleto sobre el presupuesto local?
 - ▶ La frase “efecto causal de T sobre Y ” no tiene sentido si no se sabe qué significa no tener T .
2. Cada unidad individual i tiene su propio efecto causal τ_i .
3. Pero no podemos medir el efecto causal a nivel individual, porque no podemos observar $Y_i(1)$ y $Y_i(0)$ al mismo tiempo. Esto se conoce como el **problema fundamental de la inferencia causal**. Lo que observamos es Y_i :

$$Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$$

Problema fundamental de la inferencia causal

Problema fundamental de la inferencia causal

Unidad	$Y(0)$	$Y(1)$	$Y(1) - Y(0)$
1	3	?	?
2	?	6	?
3	?	3	?
4	6	?	?
6	?	7	?
Media	4.5	5.3	0.8

Problema fundamental de la inferencia causal

Unidad	$Y(0)$	$Y(1)$	$Y(1) - Y(0)$
1	3	?	?
2	?	6	?
3	?	3	?
4	6	?	?
6	?	7	?
Media	4.5	5.3	0.8

$$Y_i = d_i Y_i(1) + (1 - d_i) Y_i(0)$$

Problema fundamental de la inferencia causal

	Resultado potencial con el programa	Resultado potencial sin el programa
Participa en el programa	Observable	No observable (contrafactual)
No participa en el programa	No observable (contrafactual)	Observable

Una solución...

Una solución...



Identificación

Efecto causal medio

- ▶ Aunque no podemos medir el efecto causal individual, $\tau_i = Y_i(1) - Y_i(0)$, podemos asignar aleatoriamente sujetos a las condiciones de tratamiento y control para estimar el **efecto causal medio**, $\bar{\tau}_i$:

$$\bar{\tau}_i = \frac{1}{N} \sum_{i=1}^N (Y_i(1) - Y_i(0)) = \overline{Y_i(1) - Y_i(0)}$$

- ▶ El efecto causal medio también se conoce como efecto medio del tratamiento (ATE).

Estimandos y preguntas causales

- ▶ Antes de hablar de la aleatorización y de cómo nos permite estimar la ATE, tener en cuenta que el ATE es un tipo de estimando.
- ▶ Un estimando es una cantidad sobre la que se quiere aprender (a partir de los datos). Es el objetivo de su investigación que *tu* eliges.
- ▶ Ser preciso sobre la pregunta de investigación significa ser preciso sobre el estimando. Para las preguntas causales, esto significa especificar:
 - ▶ El resultado
 - ▶ Las condiciones de tratamiento y control
 - ▶ La población de estudio

Otros tipos de estimandos

- ▶ El ATE para un subgrupo concreto, también conocido como efecto medio condicional del tratamiento (CATE)
- ▶ Las diferencias en los CATE: diferencias en el efecto medio del tratamiento para un grupo en comparación con otro grupo.
- ▶ El ATE sólo para las unidades tratadas, también conocido como ATT (efecto medio del tratamiento sobre los tratados).
- ▶ El ATE local (LATE). “Local” = aquéllas cuyo estado de tratamiento cambiaría por un estímulo en un diseño de aliento (alias CACE, “*complier average causal effect*”) o aquéllas en la vecindad de una discontinuidad para un diseño de regresión discontinua.

Estrategia de identificación

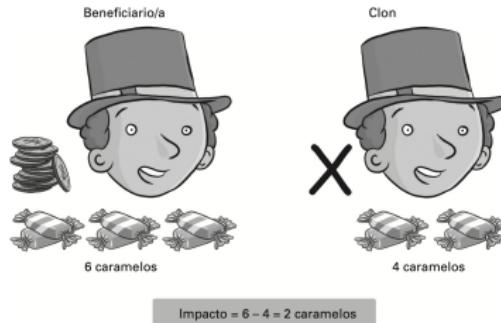
Una estrategia de identificación implica sortear el *problema fundamental de la inferencia causal*. Lo que **NO** podemos estimar:

$$E[Y_i(1)|T = 1] - E[Y_i(0)|T = 0]$$

Estrategia de identificación

Una estrategia de identificación implica sortear el *problema fundamental de la inferencia causal*. Lo que **NO** podemos estimar:

$$E[Y_i(1)|T = 1] - E[Y_i(0)|T = 0]$$



Estrategia de identificación

- ▶ La idea central es estimar el contrafactual $Y_i(0)$

Estrategia de identificación

- ▶ La idea central es estimar el contrafactual $Y_i(0)$
- ▶ Esto no puede hacerse para cada unidad que fue tratada

Estrategia de identificación

- ▶ La idea central es estimar el contrafactual $Y_i(0)$
- ▶ Esto no puede hacerse para cada unidad que fue tratada
- ▶ Se puede usar un grupo de comparación y estimar una media $E[Y_i|T = 0]$

Estrategia de identificación

Un grupo de comparación válido:

- (1) Tiene las mismas características, en promedio, que el grupo de tratamiento en ausencia del tratamiento;

Estrategia de identificación

Un grupo de comparación válido:

- (1) Tiene las mismas características, en promedio, que el grupo de tratamiento en ausencia del tratamiento;
- (2) no es afectado por el tratamiento;

Estrategia de identificación

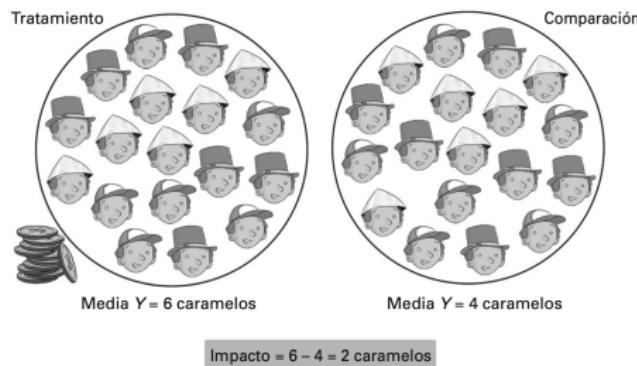
Un grupo de comparación válido:

- (1) Tiene las mismas características, en promedio, que el grupo de tratamiento en ausencia del tratamiento;
- (2) no es afectado por el tratamiento;
- (3) reaccionaría al tratamiento de la misma manera que el grupo de tratamiento, si fuera objeto del tratamiento

Estrategia de identificación

Un grupo de comparación válido:

- (1) Tiene las mismas características, en promedio, que el grupo de tratamiento en ausencia del tratamiento;
- (2) no es afectado por el tratamiento;
- (3) reaccionaría al tratamiento de la misma manera que el grupo de tratamiento, si fuera objeto del tratamiento



Supuesto de independencia

La identificación descansa en el supuesto de independencia entre el **status de tratamiento** y los **resultados potenciales**

$$Y_i(1), Y_i(0) \perp T_i$$

Supuesto de independencia

La identificación descansa en el supuesto de independencia entre el **status de tratamiento** y los **resultados potenciales**

$$Y_i(1), Y_i(0) \perp T_i$$

En ese caso, entonces:

$$\begin{aligned}ATE &= E[Y_{i1} - Y_{i0}] \\&= E[Y_{i1}] - E[Y_{i0}] \\&= E[Y_i|T = 1] - E[Y_i|T = 0]\end{aligned}$$

La expectativa de resultados potenciales no-observados es igual la expectativa condicional en la asignación del tratamiento.

¿Cuándo podemos justificar que el supuesto de independencia entre tratamiento y resultados potenciales se sostiene?

- ▶ Distintas **estrategias de identificación**

“To ask what is your identification strategy is to ask what research design (and assumptions) one intends to use for the identification of a causal effect.” (Keele, 2015)

Experimentos

Experimentos aleatorizados

Estándar de oro de las estrategias de identificación

Los sujetos son asignados a D_i en forma **aleatoria**

El investigador impone la independencia entre la **condición de tratamiento** y los **resultados potenciales**

Experimentos aleatorizados

Estándar de oro de las estrategias de identificación

Los sujetos son asignados a D_i en forma **aleatoria**

El investigador impone la independencia entre la **condición de tratamiento** y los **resultados potenciales**

Tratados y no tratados son en expectativa iguales en:

- ▶ características observables
- ▶ características no observables

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)
- ▶ Experimentos de laboratorio

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)
- ▶ Experimentos de laboratorio
- ▶ Experimentos de encuesta
- ▶ Experimentos naturales

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)
- ▶ Experimentos de laboratorio
- ▶ Experimentos de encuesta
- ▶ Experimentos naturales

Número de condiciones de tratamiento:

- ▶ Tratamiento y Control
- ▶ Múltiples “brazos” (T_1, T_2, C)

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)
- ▶ Experimentos de laboratorio
- ▶ Experimentos de encuesta
- ▶ Experimentos naturales

Número de condiciones de tratamiento:

- ▶ Tratamiento y Control
- ▶ Múltiples “brazos” (T_1, T_2, C)
- ▶ Factoriales (2×2)

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)
- ▶ Experimentos de laboratorio
- ▶ Experimentos de encuesta
- ▶ Experimentos naturales

Número de condiciones de tratamiento:

- ▶ Tratamiento y Control
- ▶ Múltiples “brazos” (T_1, T_2, C)
- ▶ Factoriales (2×2)
- ▶ Otras estrategias de aleatorización

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)
- ▶ Experimentos de laboratorio
- ▶ Experimentos de encuesta
- ▶ Experimentos naturales

Número de condiciones de tratamiento:

- ▶ Tratamiento y Control
- ▶ Múltiples “brazos” (T_1, T_2, C)
- ▶ Factoriales (2×2)
- ▶ Otras estrategias de aleatorización

Forma de asignación al tratamiento:

- ▶ Fuerza bruta

Diseños

Variedad de tipos de experimentos, por ej.:

- ▶ Experimentos de campo
 - ▶ Aleatorización de intervenciones (programas)
 - ▶ “Nudges” (o información)
- ▶ Experimentos de laboratorio
- ▶ Experimentos de encuesta
- ▶ Experimentos naturales

Número de condiciones de tratamiento:

- ▶ Tratamiento y Control
- ▶ Múltiples “brazos” (T_1, T_2, C)
- ▶ Factoriales (2×2)
- ▶ Otras estrategias de aleatorización

Forma de asignación al tratamiento:

- ▶ Fuerza bruta
- ▶ Aliento (promoción)

Nudges con tres brazos

Last Month Neighbor Comparison | You used **42% more** natural gas than your efficient neighbors.

Category	Value (Therms)
Efficient Neighbors	19
YOU	27
All Neighbors	28

* Therms: Standard unit of measuring heat energy

How you're doing:

Great ☺ ☺
► **GOOD ☺**
More than average

Who are your Neighbors?

- **All Neighbors:** Approximately 100 occupied, nearby homes that are similar in size to yours (avg 1,517 sq ft)
- **Efficient Neighbors:** The most efficient 20 percent from the "All Neighbors" group

Schultz et al. (2007)

Experimento de campo con diseño factorial

		Intervención 1	
		Tratamiento	Comparación
Intervención 2	Tratamiento	Grupo A 	Grupo C 
	Comparación	Grupo B 	Grupo D 

Fortalezas y limitaciones

Fortaleza:

- ▶ Validez interna

Limitaciones:

- ▶ Desgaste
- ▶ Efecto derrame
- ▶ Ética
- ▶ Validez externa

Validez interna y externa

Validez externa: la muestra de la evaluación representa con precisión a la población de unidades elegibles.

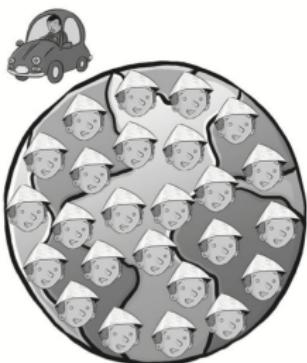
Validez interna: El impacto estimado del programa es el impacto libre de todos los demás factores de confusión potenciales (o, en otras palabras, que el grupo de comparación represente una estimación precisa del contrafactual de modo que se estime el verdadero impacto del programa).



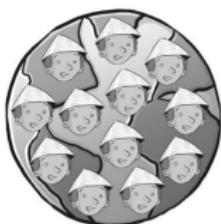
Fuente: Gertler, et al. (2017).

Validez interna y externa

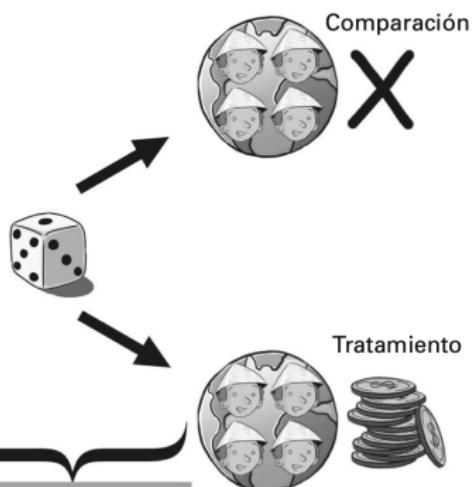
1. Definir las unidades elegibles



2. Seleccionar la muestra de evaluación



3. Asignar aleatoriamente al tratamiento



Valididad externa

Valididad interna



No elegible



Elegible

Fuente: Gertler, et al. (2017).

Respuestas a la “crisis” de validez externa

- ▶ Investigar la existencia de efectos de tratamiento heterogéneos
 - ▶ Interacción entre T_i y características de los sujetos X_i (sexo, edad, educación, lugar de residencia, etc.)
 - ▶ Depende de observables en X .

Respuestas a la “crisis” de validez externa

- ▶ Investigar la existencia de efectos de tratamiento heterogéneos
 - ▶ Interacción entre T_i y características de los sujetos X_i (sexo, edad, educación, lugar de residencia, etc.)
 - ▶ Depende de observables en X .
- ▶ Replicación

Metaketa Initiative



Metaketa Initiative Project Locations

The **Metaketa Initiative** is a collaborative research model aimed at improving the accumulation of knowledge from field experiments on topics where academic researchers and policy practitioners share substantive interests. EGAP funds and coordinates studies across countries, clustered by theme, to improve and incentivize innovative research alongside integrated analysis and publication.

Context: EGAP sees an **ongoing crisis of external validity** of development research and few systemic efforts to address it. The business-as-usual model for many academic researchers is to select topics they find interesting and seek funding to implement the research in an original way. In practice, this often means the **results may be difficult to integrate** with learning developed in **other contexts**. Other research is done in the context of policy evaluation. In these cases, the research is sometimes commissioned by development agencies and implemented by researchers. Often this research responds strongly to particular local needs but is not designed to answer questions that span variegated contexts. A consequence of this is that **major policy innovations often rest on fragile research foundations**.

For example, major lessons have been drawn on the effectiveness of community-based monitoring of health workers for health gains, or on the advantages of disseminating information on corruption about politicians—all from single studies. Yet there are well known reasons for caution, not least because of the presence of publication bias afflicting academic research. Positive results get published and read, negative or null results often disappear, and little is learned about the role that context plays in determining when a finding is relevant or not.

Solution: EGAP is trying to change this challenge of external validity; in part by **getting the incentives right** to attract the best researchers to contribute to a collective endeavor that **identifies critical areas** where **generalizable knowledge** can have a **large impact**. The key idea of this initiative is to take a major question of policy importance for governance outcomes, identify an intervention that is tried, but not tested, and implement a cluster of coordinated research studies that can provide a reliable answer to the question.

Metaketa Rounds

- I. Information and Accountability
- II. Taxation
- III. Natural Resource Governance
- IV. Community Policing
- V. Women's Action Committees and Local Services

Recent Press Publications

Eight Principles of the Metaketa Initiative

Coordination across research teams
predefined themes and comparable interventions

- Comparable measures
- Integrated case selection
- Preregistration
- Third-party analysis
- Formal synthesis
- Integrated publication

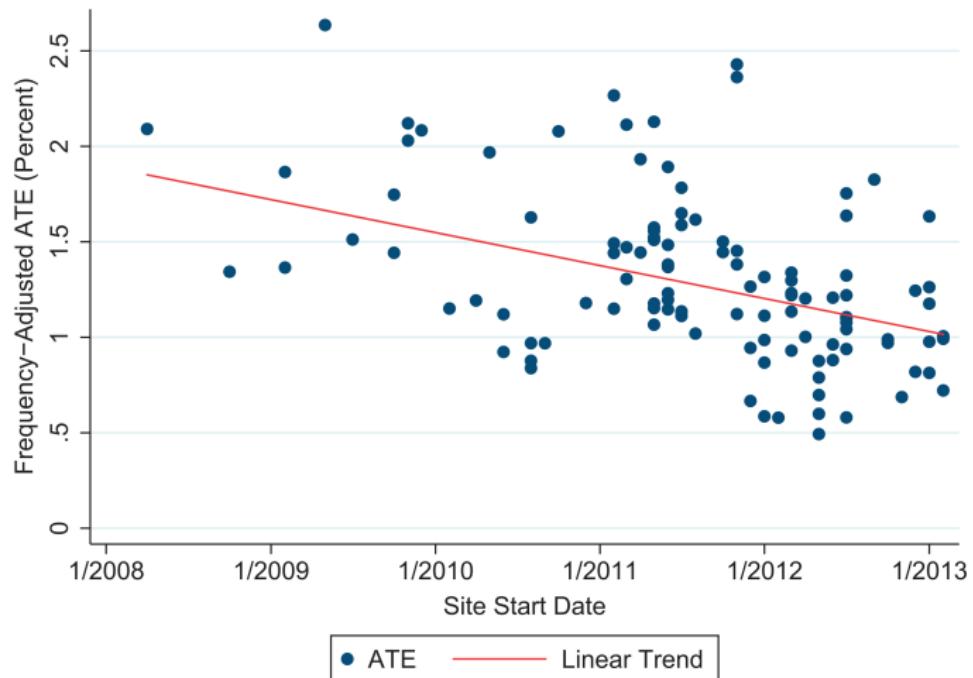
SITE SELECTION BIAS IN PROGRAM EVALUATION*

HUNT ALLCOTT

“Site selection bias” can occur when the probability that a program is adopted or evaluated is correlated with its impacts. I test for site selection bias in the context of the Opower energy conservation programs, using 111 randomized control trials involving 8.6 million households across the United States. Predictions based on rich microdata from the first 10 replications substantially overstate efficacy in the next 101 sites. Several mechanisms caused this positive selection. For example, utilities in more environmentalist areas are more likely to adopt the program, and their customers are more responsive to the treatment. Also, because utilities initially target treatment at higher-usage consumer subpopulations, efficacy drops as the program is later expanded. The results illustrate how program evaluations can still give systematically biased out-of-sample predictions, even after many replications. *JEL Codes:* C93, D12, L94, O12, Q41.

Allcott, H. (2015). Site Selection Bias in Program Evaluation. *The Quarterly Journal of Economics*, 130(3), 1117–1165. <https://doi.org/10.1093/qje/qjv015>

Replicación y sesgos de selección



Allcott, H. (2015). Site Selection Bias in Program Evaluation. *The Quarterly Journal of Economics*, 130(3), 1117–1165. <https://doi.org/10.1093/qje/qjv015>

Experimentos Naturales

- ▶ Una situación real que produce una asignación casual a un tratamiento
- ▶ Esta situación genera una asignación al tratamiento ***como si fuera aleatoria*** (as-if random)
- ▶ Requiere una fuerte justificación

Vouchers for Private Schooling in Colombia: Evidence from a Randomized Natural Experiment

By JOSHUA ANGRIST, ERIC BETTINGER, ERIK BLOOM, ELIZABETH KING,
AND MICHAEL KREMER*

Colombia used lotteries to distribute vouchers which partially covered the cost of private secondary school for students who maintained satisfactory academic progress. Three years after the lotteries, winners were about 10 percentage points more likely to have finished 8th grade, primarily because they were less likely to repeat grades, and scored 0.2 standard deviations higher on achievement tests. There is some evidence that winners worked less than losers and were less likely to marry or cohabit as teenagers. Benefits to participants likely exceeded the \$24 per winner additional cost to the government of supplying vouchers instead of public-school places. (JEL I22, J13, I28)

Angrist, Joshua, Eric Bettinger, Erik Bloom, Elizabeth King, and Michael Kremer. 2002. "Vouchers for Private Schooling in Colombia: Evidence from a Randomized Natural Experiment." *American Economic Review* 92 (5): 1535–58.

Does Indiscriminate Violence Incite Insurgent Attacks?

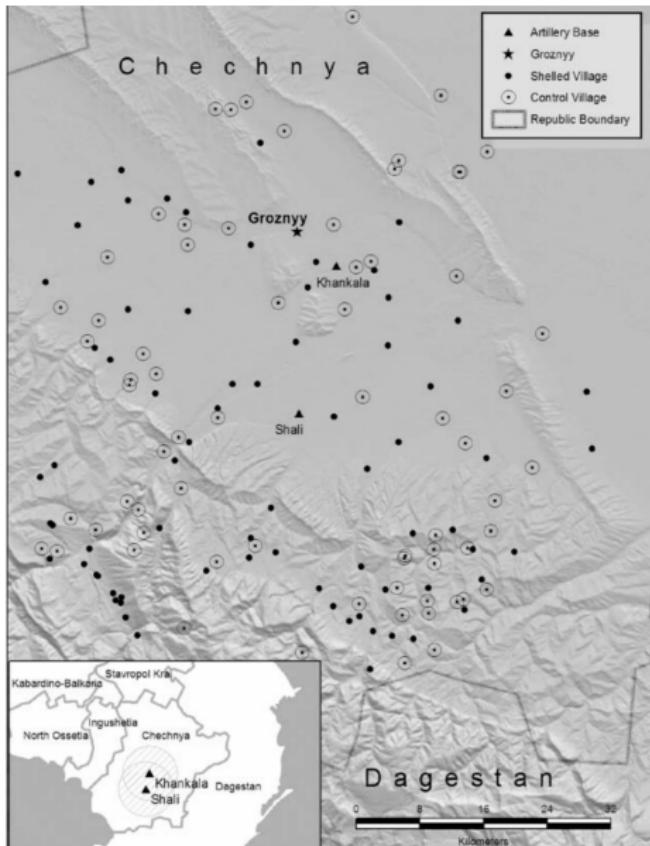
Evidence from Chechnya

Jason Lyall

Department of Politics and the Woodrow Wilson School

Princeton University, New Jersey

Does a state's use of indiscriminate violence incite insurgent attacks? To date, most existing theories and empirical studies have concluded that such violence is highly counterproductive because it creates new grievances while forcing victims to seek security, if not safety, in rebel arms. This proposition is tested using Russian artillery fire in Chechnya (2000 to 2005) to estimate indiscriminate violence's effect on subsequent patterns of insurgent attacks across matched pairs of similar shelled and nonshelled villages. The findings are counterintuitive. Shelled villages experience a 24 percent reduction in posttreatment mean insurgent attacks relative to control villages. In addition, commonly cited "triggers" for insurgent retaliation, including the lethality and destructiveness of indiscriminate violence, are either negatively correlated with insurgent attacks or statistically insignificant.



Note: One hundred forty-seven populated settlements (seventy-three treated, seventy-four control). The sample population is defined by the range of Russian artillery (see inset map).

Village Level “As-if” Randomization Tests and Postmatching Statistics

Covariates	Mean Treated	Mean Control	Mean Difference	Std. Bias	Rank Sum	K-S Test
“As if” randomization						
Population	7.364	7.020	0.344	0.209	0.248	0.133
Poverty	2.425	2.284	0.141	0.245	0.163	0.802
Tariqa	0.027	0.068	-0.041	-0.244	0.255	–
Elevation	5.933	5.756	0.177	0.225	0.202	0.169
Isolation	4.424	3.959	0.465	0.171	0.641	0.990
Neighbor	0.742	0.899	-0.157	-0.213	0.321	0.542
Garrison	0.178	0.122	0.056	0.145	0.339	–
Rebel	0.548	0.446	0.102	0.204	0.218	–

Aleatorización de la asignación al tratamiento

Aleatorización de la asignación al tratamiento

- ▶ Aleatorización significa que cada observación tiene una probabilidad conocida de asignación a las condiciones experimentales *entre 0 y 1*.
- ▶ Ninguna unidad de la muestra experimental se asigna al tratamiento con certeza ($\text{probabilidad} = 1$) o al control con certeza ($\text{probabilidad} = 0$).
- ▶ Las unidades pueden variar en su probabilidad de asignación al tratamiento.
- ▶ Por ejemplo, la probabilidad puede variar según el grupo: las mujeres pueden tener una probabilidad del 25% de ser asignadas al tratamiento, mientras que los hombres tienen una probabilidad diferente.
- ▶ Incluso puede variar entre individuos, aunque esto complicaría el análisis.

Asignación aleatoria frente a muestreo aleatorio

- ▶ Aleatorización (del tratamiento): asignación de sujetos con probabilidad conocida a las condiciones experimentales.
 - ▶ Esta asignación aleatoria del tratamiento puede combinarse con cualquier tipo de muestra (muestra aleatoria, muestra de conveniencia, etc.).
 - ▶ Pero el tamaño y otras características de la muestra afectarán a la potencia y a la capacidad de extrapolar los resultados a otras poblaciones.
- ▶ Muestreo aleatorio (de la población): selección de los sujetos de la muestra a partir de una población con una probabilidad conocida.

Aleatorización

- ▶ Queremos la ATE, $\bar{\tau}_i = \overline{Y_i(1) - Y_i(0)}$.
- ▶ Haremos uso del hecho de que la media de las diferencias es igual a la diferencia de las medias:

$$\text{ATE} = \overline{Y_i(1) - Y_i(0)} = \overline{Y_i(1)} - \overline{Y_i(0)}$$

Aleatorización

- ▶ Asignamos *aleatoriamente* algunas de nuestras unidades a la condición de tratamiento. Para estas unidades tratadas, medimos el resultado $Y_i|T_i = 1$, que es el mismo que $Y_i(1)$ para estas unidades.
- ▶ Como estas unidades se asignaron aleatoriamente al tratamiento, estos $Y_i = Y_i(1)$ para las unidades tratadas representan el $Y_i(1)$ para todas nuestras unidades.
- ▶ En expectativa (o en promedio a través de experimentos repetidos (escrito $E_R[\cdot]$)):

$$E_R[\bar{Y}_i|T_i = 1] = \overline{Y_i(1)}.$$

- ▶ El $\bar{Y}|T_i = 1$ es un estimador insesgado de la media poblacional de los resultados potenciales bajo tratamiento.
- ▶ La misma lógica se aplica a las unidades asignadas aleatoriamente al control:

$$E_R[\bar{Y}_i|T_i = 0] = \overline{Y_i(0)}.$$

Aleatorización

- ▶ Así que podemos escribir un estimador para el ATE:

$$\hat{\tau}_i = (\overline{Y_i(1)}|T_i = 1) - (\overline{Y_i(0)}|T_i = 0)$$

- ▶ En la expectativa, o en promedio a través de experimentos repetidos, $\hat{\tau}_i$ es igual al ATE:

$$E_R[Y_i|T_i = 1] - E_R[Y_i|T_i = 0] = \overline{Y_i(1)} - \overline{Y_i(0)}.$$

- ▶ Podemos simplemente tomar la diferencia de estos estimadores insesgados de $\overline{Y_i(1)}$ y $\overline{Y_i(0)}$ para obtener una estimación insesgada del ATE.

Tres supuestos clave

Para hacer afirmaciones causales con un experimento (o para juzgar si nos creemos las afirmaciones de un estudio), necesitamos tres supuestos fundamentales:

- ▶ Asignación aleatoria de los sujetos al tratamiento, lo que implica que recibir el tratamiento es estadísticamente independiente de los resultados potenciales de los sujetos.
- ▶ Suposición estabilidad del valor del tratamiento unitario (SUTVA).
- ▶ Excluibilidad, que significa que los resultados potenciales de un sujeto responden sólo al tratamiento definido, no a otros factores extraños que puedan estar correlacionados con el tratamiento.

SUTVA, parte 1

1. El resultado potencial de un sujeto sólo refleja si recibe o no el tratamiento. No se ve afectado por cómo se asignan los tratamientos a otros sujetos.
 - ▶ Una violación clásica es el caso de las vacunas y sus efectos indirectos.
 - ▶ Supongamos una persona en la condición de control (sin vacuna). Si su enfermedad ($Y_i(0)$) depende del estado de tratamiento de otras personas (si se vacunan o no), ¡es como si tuviera dos $Y_i(0)$ diferentes!
 - ▶ SUTVA (= stable unit treatment value assumption)

SUTVA, parte 2

2. No hay variaciones ocultas del tratamiento

- ▶ Digamos que el tratamiento es tomar una vacuna, pero hay dos tipos de vacunas y tienen ingredientes diferentes.
- ▶ Un ejemplo de violación es cuando la posibilidad de estar enfermo al recibir la vacuna ($Y_i(1)$) depende de la vacuna que haya tomado. Tendríamos dos $Y_i(1)$ diferentes.

Excluidabilidad

- ▶ La asignación del tratamiento no tiene ningún efecto sobre los resultados, excepto a través de su efecto sobre si se recibió el tratamiento.
 - ▶ Es importante definir el tratamiento con precisión.
 - ▶ También es importante mantener la simetría entre los grupos de tratamiento y de control (por ejemplo, mediante el enmascaramiento, con los mismos procedimientos de recogida de datos para todos los sujetos del estudio, etc.), de modo que la asignación al tratamiento sólo afecte al tratamiento recibido, y no a otras cosas como las interacciones con los investigadores que no se quieran definir como parte del tratamiento.

Aleatorización simple

- ▶ Para cada unidad, tiramos una moneda para ver si será tratada. Luego medimos la variable de resultado al mismo nivel que la moneda.
- ▶ Las monedas no tienen que ser justas (50-50), pero debemos conocer la probabilidad de asignación al tratamiento.
- ▶ No se puede garantizar un número concreto de unidades tratadas y unidades de control.
- ▶ Ejemplo: Si tiene 6 unidades y lanza una moneda justa para cada una, tiene aproximadamente un 3% de probabilidades de asignar **todas** las unidades al tratamiento o de asignar **todas** las unidades al control.

Aleatorización completa

- ▶ Se asigna al tratamiento un número fijo m de N unidades.
- ▶ La probabilidad de que una unidad se asigne al tratamiento es m/N .
- ▶ Es como tener una urna con N bolas, de las que m se marcan como tratamiento y $N - m$ como control. Las loterías públicas utilizan este método.